

Projekt MMS - Korelacja i regresja - Nazwisko1_Nazwisko2

Temat: modelowanie depresji odcinka ST (oldpeak) u pacjentów z bazy Cleveland (Heart Disease Database, UCI Machine Learning Repository).

Cel badawczy: zbadanie wpływu parametrów klinicznych pacjenta (age, trestbps, chol, thalach, ca, cp) na nasilenie depresji odcinka ST w teście wysiłkowym (oldpeak), z wykorzystaniem regresji wielorakiej oraz metod redukcji zmiennych.

1. Opis zestawu danych

Baza Cleveland (Heart Disease Database): 299 obserwacji po usunięciu braków. Zmienna objaśniana: oldpeak. Zmienne objaśniające: age, trestbps, chol, thalach, ca, cp. Atrybuty numeryczne; braki oznaczone w oryginale znakiem '?'.

Współczynniki zmienności:

age: średnia=54.44, s=9.04, CV=16.6% [WYBRANA]

trestbps: średnia=131.69, s=17.6, CV=13.36% [WYBRANA]

chol: średnia=246.69, s=51.78, CV=20.99% [WYBRANA]

thalach: średnia=149.61, s=22.88, CV=15.29% [WYBRANA]

ca: średnia=0.67, s=0.94, CV=139.45% [WYBRANA]

cp: średnia=3.16, s=0.96, CV=30.4% [WYBRANA]

2. Model regresji wielorakiej - wszystkie zmienne objaśniające

$Y = 1.4331 - 0.0052 \cdot \text{age} + 0.0114 \cdot \text{trestbps} - 0.0001 \cdot \text{chol} - 0.0136 \cdot \text{thalach} + 0.2545 \cdot \text{ca} + 0.0919 \cdot \text{cp}$

$R^2 = 0.1930$ - model wyjaśnia 19.3% wariancji oldpeak.

Prognoza dla profilu (mediany): {'age': 56.0, 'trestbps': 130.0, 'chol': 242.0, 'thalach': 153.0, 'ca': 0.0, 'cp': 3.0} -> $Y = 0.7920$

3. Metoda Pawłowskiego (k = 2)

Wybrane zmienne (numery 1..p): [3, 4] -> ['chol', 'thalach'], $\det(R) = 0.999995$

$R^2 = 0.1182$. Prognoza: 0.9866

4. Redukcja zmiennych - analiza współczynników korelacji

Wektor $|r|$ z Y : [np.float64(0.197), np.float64(0.192), np.float64(0.04), np.float64(0.341), np.float64(0.296), np.float64(0.203)]

Wybrane: ['thalach']

5. Model po redukcji (eliminacja nadmiarowych)

Po eliminacji ($r_{\text{kryt}} = 0.5$): zmienne ['thalach']

$R^2 = 0.1165$. Prognoza: 0.9914

6. Analiza pojedynczej zmiennej: chol

a) Model liniowy: $Y = 0.8279 + 0.0009 \cdot \text{chol}$, $R^2 = 0.0016$

$H_0: \rho = 0$; $H_1: \rho \neq 0$. $r = 0.0404$, $t = 0.6973$, $df = 297$

$\alpha = 0.01$: $t_{\text{kryt}} = 2.5925 \rightarrow$ Brak podstaw do odrzucenia H_0

$\alpha = 0.05$: $t_{\text{kryt}} = 1.9680 \rightarrow$ Brak podstaw do odrzucenia H_0

$\alpha = 0.1$: $t_{\text{kryt}} = 1.6500 \rightarrow$ Brak podstaw do odrzucenia H_0

b) Modele nieliniowe:

logarytmiczny: $Y = a + b \cdot \ln(\text{chol})$, $R^2 = 0.0006$

odwrotnościowy: $Y = a + b \cdot (1/\text{chol})$, $R^2 = 0.0001$

c) Wielomian: $Y = 1.8769 + -0.0071 \cdot \text{chol} + 0.0000 \cdot \text{chol}^2$, $R^2 = 0.0073$

d) Najlepszy model: wielomian, $R^2 = 0.0073$. Prognoza dla $\text{chol} = 242.00$: $Y = 1.0131$

6
5
4
3
2
1
0
oldpeak

6. Analiza pojedynczej zmiennej: thalach

a) Model liniowy: $Y = 3.6386 + -0.0173 \cdot \text{thalach}$, $R^2 = 0.1165$

$H_0: \rho = 0$; $H_1: \rho \neq 0$. $r = -0.3413$, $t = -6.2568$, $df = 297$

$\alpha = 0.01$: $t_{\text{kryt}} = 2.5925 \rightarrow \text{Odrzucamy } H_0$

$\alpha = 0.05$: $t_{\text{kryt}} = 1.9680 \rightarrow \text{Odrzucamy } H_0$

$\alpha = 0.1$: $t_{\text{kryt}} = 1.6500 \rightarrow \text{Odrzucamy } H_0$

b) Modele nieliniowe:

logarytmiczny: $Y = a + b \cdot \ln(\text{thalach})$, $R^2 = 0.1054$

odwrotnościowy: $Y = a + b \cdot (1/\text{thalach})$, $R^2 = 0.0898$

c) Wielomian: $Y = -0.2021 + 0.0377 \cdot \text{thalach} + -0.0002 \cdot \text{thalach}^2$, $R^2 = 0.1287$

d) Najlepszy model: wielomian, $R^2 = 0.1287$. Prognoza dla $\text{thalach} = 153.00$: $Y = 1.0817$

6
5
4
3
2
1
0
oldpeak

7. Podsumowanie

Porównanie R^2 : model pełny 0.1930, Pawłowski 0.1182, po eliminacji 0.1165. Redukcja zmiennych obniża złożoność; pełny model zwykle ma najwyższe dopasowanie na próbie uczącej. Wnioski kliniczne należy formułować ostrożnie – korelacja nie implikuje przyczynowości.

Podział obowiązków

Podział obowiązków:

Osoba 1: wczytanie danych, model pełny, metoda Pawłowskiego, raport PDF.

Osoba 2: eliminacja zmiennych, modele jednej zmiennej, arkusz Excel, wykresy.